RAPPORT DEFI IA 2024 - 2025

BAH AMADOU ALI
KONE ALABO MARIA YACINE
SORO DOBA ISSIAKA
UNIVERSITE FELIX HOUPHOUET BOIGNY

TABLE DES MATIÈRES

1 PRESENTATION DU DEFI IA 2024-2025 ____ 2

1.1 PROBLEMATIQUE ____ 2

1.2 OBJECTIFS ____ 3

1.3 DONNEES DISPONIBLES ____ 3

1.4 PERIODE ____ 3

1.5 METRIQUE D'EVALUATION ____ 3

2 MÉTHODOLOGIE ____ 4

2.1 EXPLORATION DES DONNEES ____ 4

2.2 FEATURE ENGINEERING ____ 4

2.3 MODÉLISATION ____ 4

2.4 EVALUATION DES PERFORMANCES ____ 4

2.5 RECOMMANDATIONS ____ 4

3 PRESENTATION DES DONNEES ____ 4

3.1 TRAIN_DATA ____ 4

3.2 PRODUCT_DATA.CSV ____ 5

3.3 TEST_DATA.CSV ____ 7

4 FEATURE ENGINEERING ____ 7

4.1 CARACTERISTIQUES DE BASE ____ 7

4.2 CARACTERISTIQUES CLIENT-PRODUIT ____ 8

4.3 AJOUT DE LA SAISONNALITE ____ 8

5 MODÉLISATION ____ 8

5.1 ÉTIQUETAGE : CREATION DE LA VARIABLE CIBLE ____ 8

5.2 APPROCHE BASÉE SUR LA FRÉQUENCE ____ 8

5.3 MODELE SUPERVISE : REGRESSION LOGISTIQUE ____ 9

5.4 MODELE SUPERVISE : XGBOOST ____ 9

5.5 MODELE SUPERVISE : LIGHTGBM ____ 9

5.6 COMPARAISON ET CHOIX DU MODELE ____ 10

6 PREDICTION DES DIX PRODUITS LES PLUS PROBABLES ____ 10

7 LIMITES ET PERSPECTIVES ____ 10

7.1 LIMITES ____ 10

7.2 PERSPECTIVES ____ 11

INTRODUCTION

Dans un environnement commercial de plus en plus compétitif, comprendre et anticiper le comportement des clients est devenu un enjeu majeur pour les entreprises. Ce projet s'inscrit dans ce contexte et vise à répondre à une problématique clé : **comment prédire les produits qu'un client est susceptible de racheter dans le futur ?**

Pour ce faire, nous avons exploité les données transactionnelles de Carrefour, couvrant les achats de milliers de clients sur une période de deux ans (2022-2023). L'objectif principal est d'utiliser ces données historiques pour construire un modèle de machine learning capable de prédire les réachats des clients en 2024.

Ce rapport détaille les étapes de la démarche adoptée pour atteindre cet objectif : depuis la compréhension et la préparation des données jusqu'à la construction d'un modèle performant et l'analyse de ses résultats.

1 PRESENTATION DU DEFI IA 2024-2025

Dans le cadre de la transformation analytique menée par Carrefour et en collaboration avec l'université de Bordeaux, le **Défi IA 2024-2025** s'est fixé pour objectif de développer un système de recommandation de produits basé sur des données transactionnelles. L'objectif principal est d'améliorer l'expérience client tout en augmentant les ventes en anticipant les achats futurs.

1.1 PROBLEMATIQUE

L'axe central de ce défi est d'identifier les produits que les clients de Carrefour sont les plus susceptibles de racheter sur la base de leur historique d'achats. La nature même des courses alimentaires (fréquence d'achat élevée et variabilité entre produits et clients) rend ce problème particulièrement intéressant.

En pratique, il s'agit de prédire **la première transaction de 20 000 clients** en 2024, en s'appuyant sur les historiques d'achats passés (2022 et 2023). Ce défi repose sur une tâche de recommandation où le modèle doit proposer une liste des **10 produits les plus susceptibles d'être achetés** par chaque client.

1.2 OBJECTIFS

- **Fidélisation des clients** : En proposant des recommandations pertinentes, le système doit améliorer l'expérience d'achat en simplifiant et en accélérant le processus.
- **Augmentation des ventes** : En anticipant les besoins des clients, Carrefour peut optimiser ses ventes et renforcer sa stratégie commerciale.
- **Création d'un modèle performant** : Le modèle doit exploiter efficacement les données historiques et les caractéristiques des produits pour maximiser la précision des prédictions.

1.3 DONNEES DISPONIBLES

Trois jeux de données sont fournis :

- **Historique d'achats (train_data)** : Transactions de 100 000 clients sur les années 2022 et 2023.
- **Données produits (products_data)** : Informations détaillées sur les produits disponibles à la vente, incluant leurs caractéristiques (bio, vegan, marque, etc.).
- **Données de validation (test_data)** : Transactions des 80 000 premiers clients en 2024, servant à valider les prédictions.

Les transactions des 20 000 derniers clients de 2024 sont masquées et représentent l'ensemble pour lequel le modèle doit fournir des recommandations.

1.4 PERIODE

- Début du défi : **12 septembre 2024**
- Fin du défi : **9 janvier 2025**

1.5 METRIQUE D'EVALUATION

Les performances des modèles sont mesurées à l'aide de la métrique **HitRate @10**, qui calcule la proportion des produits recommandés (parmi les 10 proposés) effectivement achetés par les clients.

- **Score baseline** : La méthode de base fournie obtient un score de 33 % sur les données de validation.
- **Classement final** : Basé sur les performances sur un ensemble de test caché (les 20 000 derniers clients).

Ce défi offre une opportunité unique de travailler sur des données réelles pour résoudre une problématique commerciale clé, tout en explorant des approches analytiques et des modèles prédictifs avancés.

2 MÉTHODOLOGIE

La démarche suivie dans ce projet repose sur un pipeline structuré, composé des étapes suivantes :

2.1 EXPLORATION DES DONNEES

Analyse des ensembles de données disponibles pour comprendre leur structure, identifier les valeurs manquantes et évaluer leur qualité.

2.2 FEATURE ENGINEERING

Création et enrichissement des variables explicatives afin de capturer les comportements clients et produits.

2.3 MODÉLISATION

Construction de modèles prédictifs en testant plusieurs algorithmes, notamment **LightGBM** et **XGboost**.

2.4 EVALUATION DES PERFORMANCES

Utilisation de métriques comme l'AUC-ROC, la précision et le F1-score pour comparer les modèles.

2.5 RECOMMANDATIONS

Proposition des 10 meilleurs produits à recommander à chaque client en fonction des prédictions.

Chaque étape est décrite en détail dans les sections suivantes.

3 PRESENTATION DES DONNEES

Le projet s'appuie sur trois ensembles de données principaux :

3.1 TRAIN_DATA

Ce dossier contient l'historique des transactions de 100 000 clients de Carrefour. Il est subdivisé en 10 parties, chaque partie représentant les transactions de 10 000 clients pour les années 2022 et 2023. Par exemple, *train_data.csv_part_1* contient les transactions des clients *customer_1* à *customer_10000*, tandis que *train_data.csv_part_2* couvre les transactions des clients *customer_10001* à *customer_20000*, et ainsi de suite.

3.1.1 STRUCTURE DES DONNÉES

Les données des transactions des clients sont structurées comme suit :

- ***date*** : La date de la transaction
- ***transaction_id*** : L'ID unique de la transaction

- ***customer_id*** : L'ID unique du client
- ***product_id*** : L'ID du produit acheté
- ***has_loyality_card*** : Indicateur de la présence d'une carte de fidélité pour le client
- ***store_id*** : L'ID du magasin où l'achat a été effectué
- ***is_promo*** : Indicateur si le produit est en promotion
- ***quantity*** : La quantité du produit achetée
- ***format*** : Le format de l'activité e-commerce (clcv, lex, ou DRIVE)
    - *clcv* : Cours livrés chez vous
    - *lex* : Livraison express
    - *DRIVE* : Retrait en magasin
- ***orderChannelCode*** : Indicateur de l'activité en ligne (site web ou application mobile)

3.1.2 EXAMEN DES DONNEES

Une fois le jeu de données entièrement chargé, il a été constaté qu'il ne contient aucune donnée manquante.

3.2 PRODUCT_DATA.CSV

Cet ensemble de données contient des informations détaillées sur les produits Carrefour.

3.2.1 STRUCTURE DES DONNÉES

Le fichier contient les colonnes suivantes :

- ***product_id*** : ID unique du produit
- ***product_description*** : Description textuelle du produit
- ***department_key*** : Clé du département
- ***class_key*** : Clé de la classe
- ***subclass_key*** : Clé de la sous-classe
- ***sector*** : Nom du secteur
- ***brand_key*** : Clé de la marque
- ***shelf_level1*** : Catégorie de niveau supérieur de l'étagère
- ***shelf_level2*** : Catégorie de deuxième niveau de l'étagère
- ***shelf_level3*** : Catégorie de troisième niveau de l'étagère
- ***shelf_level4*** : Catégorie de quatrième niveau de l'étagère
- ***bio*** : Indicateur de si le produit est biologique

- ***sugar_free*** : Indicateur de si le produit est sans sucre
- ***aspartame_free*** : Indicateur de si le produit est sans aspartame
- ***gluten_free*** : Indicateur de si le produit est sans gluten
- ***halal*** : Indicateur de si le produit est halal
- ***casher*** : Indicateur de si le produit est casher
- ***eco_friendly*** : Indicateur de si le produit est écologique
- ***local_french*** : Indicateur de si le produit est fabriqué localement en France
- ***artificial_coloring_free*** : Indicateur de si le produit est sans colorants artificiels
- ***taste_enhancer_free*** : Indicateur de si le produit est sans exhausteurs de goût
- ***naturality*** : Score de naturalité
- ***antibiotic_free*** : Indicateur de si le produit est sans antibiotiques
- ***reduced_sugar*** : Indicateur de si le produit a une teneur réduite en sucre
- ***vegetarian*** : Indicateur de si le produit est végétarien
- ***pesticide_free*** : Indicateur de si le produit est sans pesticides
- ***grain_free*** : Indicateur de si le produit est sans céréales
- ***no_added_sugar*** : Indicateur de si le produit n'a pas de sucre ajouté
- ***salt_reduced*** : Indicateur de si le produit a une teneur réduite en sel
- ***nitrite_free*** : Indicateur de si le produit est sans nitrites
- ***fed_without_ogm*** : Indicateur de si les animaux ont été nourris sans OGM
- ***no_added_salt*** : Indicateur de si le produit n'a pas de sel ajouté
- ***no_artificial_flavours*** : Indicateur de si le produit n'a pas de saveurs artificielles
- ***porc*** : Indicateur de si le produit contient du porc
- ***vegan*** : Indicateur de si le produit est végétalien
- ***frozen*** : Indicateur de si le produit est congelé
- ***fat_free*** : Indicateur de si le produit est sans matières grasses
- ***reduced_fats*** : Indicateur de si le produit a une teneur réduite en graisses
- ***fresh*** : Indicateur de si le produit est frais
- ***alcool*** : Indicateur de si le produit contient de l'alcool
- ***lactose_free*** : Indicateur de si le produit est sans lactose
- ***phenylalanine_free*** : Indicateur de si le produit est sans phénylalanine
- ***palm_oil_free*** : Indicateur de si le produit est sans huile de palme

- ***ecoscore*** : Score écologique
- ***produits_du_monde*** : Indicateur de si le produit est un produit international
- ***regional_product*** : Indicateur de si le produit est un produit régional
- ***national_brand*** : Indicateur de si le produit appartient à une marque nationale
- ***first_price_brand*** : Indicateur de si le produit appartient à une marque premier prix
- ***carrefour_brand*** : Indicateur de si le produit appartient à la marque Carrefour

3.2.2 EXAMEN DES DONNÉES

Lors de l'analyse, plusieurs observations ont été faites :

- Il contient 82 966 produits différents.
- Des données manquantes ont été relevées dans les colonnes suivantes : ***brand_key***, ***shelf_level3***, ***shelf_level4*** et ***ecoscore***.
- Certaines colonnes, comme ***lactose_free***, ***No_added_salts***, ***Salt_reduced*** et ***Naturality***, n'apportent aucune information pertinente car leurs valeurs sont uniformes sur l'ensemble du jeu de données.

3.3 TEST_DATA.CSV

Transactions réelles des 80 000 premiers clients en 2024, servant de référence pour évaluer les prédictions.

4 FEATURE ENGINEERING

Le Feature engineering est une étape essentielle du processus de modélisation. Il consiste à enrichir le jeu de données en créant de nouvelles variables basées sur une analyse approfondie des données et une meilleure compréhension du contexte. Cette démarche permet de mieux capturer les éléments pertinents et d'améliorer les performances des modèles.

4.1 CARACTERISTIQUES DE BASE

Des caractéristiques de base ont été construites pour décrire les comportements des clients ainsi que les attributs des produits :

- **Nombre total de transactions** : Mesure la fréquence globale d'achat d'un client.
- **Nombre de produits uniques achetés** : Indique la diversité des produits dans le panier d'un client.
- **Taux d'achat en promotion** : Proportion des transactions où les produits ont été achetés en promotion.

4.2 CARACTERISTIQUES CLIENT-PRODUIT

Des caractéristiques spécifiques à chaque combinaison client-produit ont également été calculées :

- **Nombre d'achats d'un produit spécifique** : Permet de mesurer la fidélité d'un client envers un produit donné.
- **Récence des achats** : Nombre de jours écoulés depuis le dernier achat d'un produit, utilisé pour capturer la fraîcheur de la relation client-produit.
- **Proportion des quantités achetées** : Représente la part des quantités d'un produit spécifique par rapport au total des achats d'un client.

4.3 AJOUT DE LA SAISONNALITE

Les habitudes d'achat évoluant souvent au fil des saisons, une caractéristique liée à la saisonnalité a été introduite.

Préférence saisonnière : Cette variable mesure la proportion des achats effectués chaque mois, afin de capturer les variations saisonnières dans les comportements d'achat.

5 MODÉLISATION

5.1 ÉTIQUETAGE : CREATION DE LA VARIABLE CIBLE

Pour répondre au défi de prédiction, nous avons créé une variable cible binaire (target) indiquant si un produit a été acheté en 2024 par un client donné. Cette variable est obtenue en comparant les combinaisons client-produit présentes dans les ensembles train_data (historique 2022-2023) et test_data (achats 2024). Une jointure sur les colonnes customer_id et product_id permet de marquer les paires correspondant à un réachat (target = 1), tandis que les autres restent à 0.

Cette démarche transforme le problème en une tâche de classification binaire, adaptée à la prédiction de réachats. Elle garantit que le modèle est entraîné pour identifier précisément les combinaisons pertinentes, en se basant sur des exemples positifs (réachats) et négatifs (non-réachats), tout en alignant l'entraînement avec l'objectif final de l'évaluation.

5.2 APPROCHE BASÉE SUR LA FRÉQUENCE

Notre première méthode s'est appuyée sur l'amélioration du modèle proposé par le défi la fréquence des achats pour recommander les 10 produits les plus souvent achetés par chaque client, obtenant **un Hitrate@10 de 0.32**.

Pour améliorer ce modèle de base, nous avons intégré la récence des achats, via un score pondéré donnant plus de poids aux produits récemment achetés, et ajouté la

popularité globale des produits pour capturer les tendances générales. Ces ajustements, combinés en un score final équilibré, ont permis d'augmenter le **Hitrate@10 à 0.35**.

5.3 MODELE SUPERVISE : REGRESSION LOGISTIQUE

Pour aller au-delà des limites du modèle basé sur la fréquence, nous avons expérimenté un modèle supervisé de régression logistique. Ce modèle, simple mais efficace, est particulièrement adapté aux problèmes de classification binaire et tire parti des caractéristiques enrichies que nous avons générées. Grâce à sa capacité à estimer directement les probabilités, il a permis de classer les produits en fonction de leur probabilité de réachat.

Cependant, bien qu'il offre une interprétabilité intéressante et une mise en œuvre rapide, ses performances restent limitées face à des modèles plus complexes comme XGBoost ou LightGBM, qui exploitent mieux les interactions non linéaires entre les caractéristiques.

5.4 MODELE SUPERVISE : XGBOOST

Pour surmonter les limites des approches plus simples, nous avons introduit XGBoost, un modèle supervisé performant capable de capturer des relations complexes entre clients et produits. Ce modèle s'appuie sur des arbres de décision optimisés et utilise les caractéristiques enrichies de notre Jeu de données pour gérer les interactions non linéaires.

Grâce à sa robustesse contre le surapprentissage et sa capacité à traiter efficacement de grands volumes de données, **XGBoost a obtenu un Hitrate@10 de 0.3825**, surpassant d'autres modèles testés dans ce contexte. Cela en fait un candidat solide pour prédire les réachats futurs.

5.5 MODELE SUPERVISE : LIGHTGBM

Nous avons également testé LightGBM, un modèle adapté aux grands ensembles de données grâce à sa construction optimisée d'arbres en histogrammes. Intégré dans le même pipeline que XGBoost, il offre une rapidité d'entraînement remarquable tout en exploitant les caractéristiques enrichies.

Bien que sa **performance en termes de Hitrate@10 de 0.3811** soit légèrement inférieure à celle de XGBoost, LightGBM reste une alternative rapide et efficace. Son utilisation peut être avantageuse dans des environnements où la vitesse d'exécution est cruciale.

5.6 COMPARAISON ET CHOIX DU MODELE

Après avoir comparé XGBoost et LightGBM dans des conditions identiques (**pipeline d'entraînement, division des données 80%/20%, et évaluation sur des métriques comme Recall, F1 Score, et ROC AUC**), XGBoost s'est démarqué par sa capacité à capturer les relations complexes dans les données. Bien que les performances de LightGBM soient très proches, la légère supériorité de XGBoost en fait notre choix final.

6 PREDICTION DES DIX PRODUITS LES PLUS PROBABLES

Après l'entraînement du modèle XGBoost, nous avons généré des recommandations personnalisées pour chaque client en suivant un processus méthodique :

- **Prédiction des probabilités d'achat** : Chaque produit a été évalué selon la probabilité qu'il soit acheté par un client donné.
- **Classement des produits** : Les produits ont été classés par ordre décroissant de probabilité.
- **Sélection des Top 10** : Pour chaque client, seuls les 10 produits avec les probabilités les plus élevées ont été retenus comme recommandations finales.
- **Calcul du Hitrate@10** : Cette métrique a permis d'évaluer la pertinence des prédictions en mesurant combien de fois les produits recommandés contiennent réellement les achats futurs du client.

Résultats obtenus avec XGBoost :

- **Hitrate@10 (ensemble d'entraînement)** : 0.3911
- **Hitrate@10 (soumission)** : 0.3825

Ces résultats montrent la capacité du modèle à fournir des recommandations pertinentes, bien qu'il reste une légère perte de performance en phase de soumission.

7 LIMITES ET PERSPECTIVES

7.1 LIMITES

Malgré les progrès réalisés dans ce projet, plusieurs contraintes ont limité nos performances et notre capacité à approfondir certaines analyses :

- **Ressources matérielles insuffisantes** :La gestion des grandes quantités de données a été un défi majeur en raison des capacités limitées de nos machines. La taille importante du jeu de données a considérablement ralenti les traitements et rendu certaines optimisations difficiles à mettre en œuvre. Un accès à des ressources matérielles plus adaptées, comme des machines avec une puissance de calcul accrue ou un environnement cloud, aurait permis d'améliorer l'efficacité de nos analyses.

- **Optimisation des hyperparamètres** : L'optimisation des hyperparamètres, essentielle pour maximiser les performances des modèles, a été contrainte par le manque de puissance de calcul. En utilisant des outils spécialisés ou des frameworks de calcul distribué, nous aurions pu explorer un espace d'hyperparamètres plus vaste et affiner davantage nos modèles.

- **Gestion des grandes données** : La volumétrie des données a complexifié les différentes étapes du pipeline, depuis le prétraitement jusqu'à l'entraînement des modèles. Ces contraintes ont parfois ralenti les itérations et réduit la profondeur de nos analyses. Un accès à des infrastructures comme des clusters de calcul ou des services cloud aurait significativement facilité ces traitements.

- **Organisation et gestion du travail en équipe** : Nous avons également identifié des lacunes dans notre méthodologie de travail en équipe. Une meilleure planification, une répartition plus claire des tâches, ainsi qu'une coordination renforcée auraient permis d'optimiser nos efforts et d'améliorer l'efficacité globale du projet.

7.2 PERSPECTIVES

Ces limites offrent plusieurs pistes d'amélioration pour de futurs projets similaires :

- **Investir dans des outils de calcul avancés** : Adopter des solutions basées sur le cloud, comme des services AWS ou Google Cloud, permettrait de gérer efficacement les volumes de données importants. Cela inclurait également l'utilisation de GPU ou TPU pour accélérer l'entraînement des modèles.

- **Optimisation des ressources locales** : Une meilleure maîtrise de nos machines actuelles, en termes d'allocation mémoire ou de gestion de la carte graphique, pourrait également améliorer l'efficacité des traitements.

- **Approfondir les compétences techniques** : Approfondir notre connaissance des techniques avancées d'optimisation et des outils de calcul distribué nous permettrait d'explorer des modèles plus complexes et d'améliorer nos résultats.

- **Renforcer la gestion de projet et le travail en équipe** : Appliquer des méthodologies de planification adaptées, comme SCRUM, nous aiderait à mieux structurer nos projets. Cela inclurait une répartition plus claire des rôles et des tâches, ainsi qu'un suivi régulier des progrès pour garantir une meilleure coordination entre les membres de l'équipe.

CONCLUSION

Ce projet a permis de relever un défi clé dans le domaine de la data science appliquée au commerce de détail : prédire les réachats de produits pour optimiser l'expérience client et augmenter les ventes. Grâce à l'analyse approfondie des données transactionnelles et à l'enrichissement des caractéristiques, nous avons pu développer un modèle basé sur XGBoost, offrant des recommandations pertinentes avec un Hitrate@10 de 0.3825.
Malgré les contraintes rencontrées, notamment au niveau des ressources matérielles et de la gestion des grandes données, ce projet ouvre des perspectives prometteuses. Les résultats obtenus démontrent le potentiel des approches supervisées pour résoudre des problématiques complexes de recommandation.
À l'avenir, l'intégration de solutions cloud, le renforcement des compétences techniques et une méthodologie de gestion de projet plus structurée pourraient permettre d'améliorer significativement les performances et la rapidité des analyses.